


¿Cuánto difieren las calificaciones de Manhattan y Brooklyn?

Estimación puntual, bootstrap propio y simulación Monte Carlo sobre Airbnb Nueva York

Grupo 25 · José Flores, Sebastian Alcaide, Pedro Ortiz y Miguel Primera



0,0181

puntos de diferencia estimada (Δ)


Calificaciones por distrito

Entrega 1: ANOVA de cinco medias, $F = 11,3048$ ($p < 0,001$). V de Cramér = 0,0200. Aquí estimamos μ_M , μ_B y su diferencia.

- M** $\mu_M = E(\text{calificación} \mid \text{Manhattan})$
- B** $\mu_B = E(\text{calificación} \mid \text{Brooklyn})$
- Δ** $\Delta = \mu_M - \mu_B$, en puntos (escala 1–5)

Elegidos por ser los dos distritos con más anuncios, no por tener el mayor y el menor promedio.

Media por distrito (Entrega 1)



Eje vertical desde 3,0 para hacer visibles las diferencias.

Datos y alcance del análisis

● **102.058**

anuncios tras la limpieza (de 102.599; 541 duplicados)

● **43.418**

calificaciones válidas en Manhattan (140 sin calificar)

● **41.515**

calificaciones válidas en Brooklyn (116 sin calificar)

Supuestos y alcance

- Unidad de análisis: un anuncio, con peso 1. No observamos a cada huésped.
- Anuncios independientes dentro y entre distritos.
- Escala ordinal 1–5 tratada como numérica al promediar.
- No imputamos calificaciones faltantes.
- Inferencia para anuncios calificados comparables a esta fuente, no para todo NYC.

Estimadores y sus propiedades

Estimadores

$$\hat{\mu}_g = \bar{Y}_g = (1/n_g) \cdot \sum Y_{gi}$$

$$\Delta = \bar{Y}_M - \bar{Y}_B$$

$$EE(\bar{Y}_g) = s_g / \sqrt{n_g}$$

$$EE(\Delta) = \sqrt{(s_M^2/n_M + s_B^2/n_B)}$$

Estimación puntual: valor que toma el estimador en nuestra muestra.

Insesgado

1

$E(\bar{Y}_g) = \mu_g$ si cada dato tiene esperanza μ_g . No corrige selección ni calificaciones faltantes.

Consistente

2

Por la ley de los grandes números, $\bar{Y}_g \rightarrow \mu_g$ cuando n_g crece.

Eficiencia lineal

3


Con datos independientes de igual varianza: mínima varianza entre estimadores lineales insesgados.

Estimación clásica de la diferencia

Estimador	n	Valor	Error estándar	IC 95%
Media Manhattan	43.418	3,2765	0,00619	[3,2644; 3,2887]
Media Brooklyn	41.515	3,2585	0,00636	[3,2460; 3,2709]
Diferencia M – B	84.933	0,0181	0,00888	[0,0007; 0,0355]

IC 95% de $\Delta = \mu_M - \mu_B$ (puntos)

El límite inferior (0,0007) queda muy cerca de cero.



Procedimiento de bootstrap

1

Datos

$n_M = 43.418$ y
 $n_B = 41.515$
calificaciones
observadas.

2

Remuestrear

Sortear con
reemplazo, del
mismo tamaño,
en cada distrito.

3

Calcular

$\bar{Y}^*M$, $\bar{Y}^*B$ y $\Delta^* =$
 $\bar{Y}^*M - \bar{Y}^*B$ en
cada remuestra.

4

Repetir

$B = 20.000$
veces. Guardar
los estadísticos.

5

Resumir

EE = desv.
estándar de las
réplicas. IC =
percentiles 2,5 y
97,5.

Origen y uso actual

Efron (1979). Estima errores estándar e intervalos de estadísticas con distribución difícil de derivar.



Implementación propia

Función propia en NumPy que sortea índices con reemplazo. $B = 20.000$ réplicas por distrito.

Relevancia moderna

Se aplica a medianas, cuantiles y regresión. Su validez depende de los supuestos de muestreo.

Distribución de las réplicas bootstrap



0,00884

EE bootstrap de Δ

[0,0006; 0,0354]

IC percentil 95% (barras oscuras)

0,00004

desplazamiento numérico por B finito;
sesgo teórico 0

Clásico y bootstrap coinciden

Para Δ	Clásico	Bootstrap
Error estándar	0,008875	0,008844
Límite inferior 95%	0,000665	0,000550
Límite superior 95%	0,035455	0,035416

0,996

razón entre errores estándar
(bootstrap / clásico)

Con $B = 20.000$, el EE simulado (0,008844) está a 0,35% de la fórmula exacta condicional (0,008875). Con $B = 500$ y 2.500, el límite inferior aún era negativo.

¿Por qué coinciden?

El estimador es una media y las muestras son grandes: ambos métodos aproximan lo mismo.

Ventajas del bootstrap aquí

Muestra la distribución completa y se extiende a estadísticos sin fórmula simple.

Límites

B finito deja error numérico. No agrega datos ni corrige selección, dependencia o faltantes.

Monte Carlo: el modelo

Idea: repetir muchas veces un modelo aleatorio explícito para estimar probabilidades y precisión.

Puntuación $\in \{1, \dots, 5\}$ con probabilidades observadas. En cada distrito:


$(C_1, \dots, C_5) \sim \text{Multinomial}(n_g, p_1, \dots, p_5)$

$\bar{Y}_g = \sum k \cdot C_k / n_g$


- A** Modelo ajustado: cada distrito con su distribución observada ($\Delta_0 = 0,0181$).
- N** Modelo nulo: ambos con la distribución conjunta ($\Delta = 0$), para medir falsos rechazos.

Decisión: prueba de Welch bilateral con $\alpha = 5\%$ en cada realización.

Probabilidad por calificación



Más muestra, más poder de detección



52,83%

potencia bajo el modelo ajustado ($\approx 53\%$);
IC Monte Carlo [52,14%; 53,52%]

5,34%


potencia con 200 anuncios por distrito:
casi el nivel del 5%

4,97–5,40%

falsos rechazos del modelo nulo, cerca
del 5% nominal

Precisión y error de simulación

P(error de estimación $\leq 0,05$ puntos)



Con tamaños originales, el evento ocurrió en las 20.000 realizaciones; límite inferior Wilson: 99,98%. Es condicional al modelo, no una certeza.

¿Cuántas realizaciones R?

R	Potencia (n = 1.000)	EE Monte Carlo
1.000	5,50%	0,00721
5.000	6,58%	0,00351
10.000	6,20%	0,00241
20.000	6,13%	0,00170

R controla el error numérico: margen máximo de 0,69 puntos porcentuales con R = 20.000.

n controla la variabilidad estadística. Más simulaciones no agregan anuncios observados.

Conclusiones

0,0181

puntos de diferencia entre
Manhattan (3,2765) y Brooklyn
(3,2585) en la escala 1–5

1

Estimación

IC 95% clásico [0,0007; 0,0355] y bootstrap [0,0006; 0,0354]: misma incertidumbre (razón de EE 0,996).

2

Simulación

Potencia original $\approx 53\%$ bajo el modelo ajustado. Error $\leq 0,05$ en 20.000/20.000 simulaciones. Con $n = 200$, potencia $\approx 5\%$.

3

Magnitud

Detectable en muestras grandes, pero pequeña. Que sea detectable no implica que sea relevante.

4

Alcance

Asociación en anuncios de esta fuente. No hay causalidad ni generalización a todo NYC.

Límites y uso de IA

Límites que condicionan la lectura

- Al incorporar 256 anuncios sin calificación con distrito conocido: cotas descriptivas de Δ [0,0059; 0,0299]. No son IC.
- Independencia supuesta y escala ordinal promediada.
- Contraste de dos distritos, sin causalidad.
- Potencia condicionada a probabilidades ajustadas con estos datos.

Uso de IA

ChatGPT/Codex: análisis, código y actualización de los archivos. Claude: revisión y presentación inicial. El grupo responde por el contenido.

Referencias

- Efron (1979). Bootstrap Methods: Another Look at the Jackknife. Ann. Stat. 7(1).
- Shalizi (2018). Simulation for Inference I — The Bootstrap.
- NIST, Monte Carlo Tool · NumPy, Generator.multinomial.
- Airbnb Open Data (NYC), Kaggle, v1.